

Определение токсичности комментариев

Екатерина Бойкова

Final Projects. NLP-course. Spring 2026 replay

2026

Код проекта: https://github.com/Ekotik15/Determining_the_toxicity_of_comments-

Аннотация

В работе исследуется бинарная классификация токсичных англоязычных комментариев Civil Comments. Цель проекта - построить воспроизводимый протокол и сравнить классические методы с современным Transformer-подходом на одинаковых train/validation/test split. Рассматриваются DummyClassifier, логистическая регрессия на словных TF-IDF-признаках, калиброванный Linear SVM на словных и символьных признаках и дообученный DistilBERT. Модель, checkpoint и порог решения выбираются только по validation, после чего фиксированная конфигурация один раз оценивается на независимом test. Bootstrap-интервалы и анализ ошибок показывают неопределенность и ограничения лучшего подхода. Работа не заявляет state of the art, но содержит прямое экспериментальное сравнение с Transformer-моделью.

На test DistilBERT получил $F1=0.637$ и $PR-AUC=0.693$, классический SVM — $F1=0.554$ и $PR-AUC=0.594$.

1. Introduction

Автоматическая модерация необходима для площадок, на которых ручная проверка каждого сообщения невозможна. Задача токсичности сложна из-за дисбаланса, субъективности разметки, зависимости от контекста и того, что одинаковая лексика может встречаться как в прямом оскорблении, так и в цитате или критическом обсуждении. False negative пропускает потенциально вредный контент, а false positive может необоснованно ограничить допустимое высказывание.

Формально для комментария x требуется оценить вероятность токсичности $p(y=1|x)$ и получить метку $\hat{y} \in \{0,1\}$. Положительный класс составляет около 8%, поэтому ассигнату не используется как основной критерий.

Работа отвечает на четыре исследовательских вопроса:

- RQ1. Насколько сильным baseline является линейная модель на TF-IDF при существенном дисбалансе классов?
- RQ2. Улучшает ли объединение словных и символьных признаков итоговую конфигурацию относительно словного baseline?
- RQ3. Как выбор порога влияет на precision, recall и F1 токсичного класса?
- RQ4. Улучшает ли дообученный DistilBERT качество относительно лучшего классического подхода при одинаковом протоколе?

Основные результаты и вклад проекта:

- реализован протокол train/validation/test без использования test для выбора модели, гиперпараметров или порога;
- все модели оцениваются единым набором метрик;
- DistilBERT дообучается и сравнивается с классическими моделями на тех же split;

- классический подход доведен до воспроизводимого CLI-эксперимента с сохранением метрик, графиков, модели и предсказаний;
- добавлены bootstrap-интервалы, сравнение порогов и анализ реальных ошибок;
- Streamlit-приложение демонстрирует сохранённую классическую SVM с её validation-порогом; Transformer запускается отдельно.

1.1. Team

Екатерина Бойкова выполнила постановку задачи, подготовку данных, разработку и сравнение моделей, анализ результатов, оформление отчета и демонстрационного приложения.

2. Related Work

Линейные модели на TF-IDF остаются полезными baseline для классификации текста: они быстры, сравнительно интерпретируемы и не требуют GPU. Символьные n-граммы особенно уместны для пользовательского контента, поскольку устойчивы к опечаткам, обфускации и вариантам написания токсичной лексики.

Duchêne et al. [1] сравнили CNN, RNN, BERT, DistilBERT, RoBERTa, XLNet и CCT на Civil Comments. В их многометочной постановке Transformer-модели достигли AUROC около 0.98, а RoBERTa с focal loss показала лучший AUROC среди рассмотренных конфигураций. DistilBERT обеспечил близкое качество при меньшем времени инференса. Выбранные численные результаты этой работы приведены ниже.

Model	Protocol	AUROC	Macro F1	Recall
DistilBERT	multilabel, 310k train	0.9804	0.3879	0.9001
RoBERTa BCE	multilabel, 310k train	0.9813	0.4749	0.8891
RoBERTa focal loss	multilabel, 310k train	0.9818	0.4648	0.8839
BiLSTM	multilabel, 310k train	0.9754	0.3638	0.8761

Прямое ранжирование этих значений и результатов настоящего проекта некорректно: в [1] использованы многометочная постановка, около 310 тысяч обучающих примеров, другие признаки целевой переменной и иной протокол оценки. Таблица показывает уровень previous art и мотивирует следующий этап исследования, но не является основанием для заявления SotA.

Borkan et al. [2] предложили subgroup AUC, BPSN AUC и BNSP AUC для измерения unintended bias. Эти метрики обнаруживают случаи, когда общая ROC-AUC скрывает систематические ошибки на комментариях с упоминаниями идентичностей. Vaidya et al. [3] исследовали multi-task learning с совместным предсказанием токсичности и идентичностей. Reichert et al. [4] сравнили балансировку, TF-IDF, GloVe, нейронные сети и LSTM. Nanda et al. [5] показали, что лидер по общей AUC не обязательно является лучшим по fairness-метрикам.

DistilBERT [9] получен дистилляцией BERT: меньшая модель сохраняет значительную часть качества исходной архитектуры при меньших вычислительных затратах. Это делает его подходящим современным baseline для учебного проекта. Настоящая работа не переносит числа из previous art в итоговое сравнение, а дообучает DistilBERT и оценивает его в том же бинарном протоколе, что и классические модели.

3. Task and Dataset

Используется mteb/toxic_conversations_50k [7], подготовленный на основе Jigsaw Unintended Bias in Toxicity Classification [6] и Civil Comments. Данные содержат англоязычные комментарии новостных площадок. Лицензия опубликованной версии - CC BY 4.0. В используемом Parquet-представлении доступны 50 000 train- и 50 000 test-строк с бинарными полями text и label.

Положительная метка соответствует токсичному комментарию. Перед обучением удаляются пустые строки и дубликаты по тексту. Из train дополнительно исключаются строки, дословно

встречающиеся в test. После очистки train делится стратифицированно в пропорции 80/20; исходный test сохраняется независимым.

Split	Rows	Toxic	Toxic share	Median chars
train	39,832	3,166	7.95%	204
validation	9,958	791	7.94%	209
test	49,896	3,947	7.91%	202

Баланс классов практически одинаков во всех split: 7.91-7.95% токсичных комментариев. Это снижает риск случайного изменения prior между split, но не устраняет проблему редкого положительного класса.

3.1. Data provenance and risks

Код загружает публичное Parquet-представление набора и кэширует его локально. Для полного воспроизведения следует сохранять дату доступа, URL и контрольные суммы кэшированных файлов, поскольку автоматически конвертируемый источник может обновляться. Карточка набора указывает на дополнительную обработку в MTEB/MMTEB, поэтому в библиографии приведены как исходная Jigsaw-задача, так и MTEB [6-8].

Разметка токсичности субъективна и может содержать неоднозначные случаи. Данные также отражают язык и общественный контекст периода сбора. Модель не должна использоваться как единственный механизм блокировки пользователя.

4. Proposed Approach

4.1. Text representation

Словный векторизатор использует униграммы и биграммы, min_df=2, max_df=0.995, sublinear TF и до 40 000 признаков. Символьный векторизатор использует char_wb n-граммы длины 3-5, min_df=3, sublinear TF и до 40 000 признаков.

Для документа d и термина t используется вес $TF\text{-}IDF(t,d) = TF(t,d) \times \log(N / DF(t))$, где N - число документов, а DF(t) - число документов, содержащих терм. При sublinear TF исходная частота заменяется на $1 + \log(TF)$.

4.2. Classifier and calibration

Объединенный разреженный вектор подается в LinearSVC с C=1.5 и class_weight="balanced". Decision scores калибруются sigmoid-методом на трех фолдах с помощью CalibratedClassifierCV. Порог выбирается на validation по максимуму F1 положительного класса.

SMOTE не используется: интерполяция разреженных TF-IDF-векторов создает точки, которые не соответствуют реальным текстам. Дисбаланс учитывается весами классов, целевой метрикой и выбором порога.

4.3. Competitive approaches

Сравниваются четыре конфигурации:

- Dummy prior - нижняя граница, использующая только частоту классов;
- word TF-IDF + Logistic Regression с C=4.0, class_weight="balanced" и solver="liblinear";
- word+character TF-IDF + calibrated Linear SVM - основной классический кандидат;
- DistilBERT - современный Transformer-baseline с взвешенной cross-entropy.

Сравнение показывает преимущество итоговой конфигурации, но не является строгой абляцией символьных признаков: одновременно меняются представление, классификатор и калибровка. Поэтому улучшение нельзя приписывать только character n-граммам.

4.4. Transformer baseline

Используется `distilbert-base-uncased` с классификационной головой на два класса. Вес токсичного класса равен отношению числа отрицательных примеров к положительным. Лучший checkpoint выбирается по validation F1; затем отдельный decision threshold выбирается на validation и без изменений применяется к test. Mixed precision включается только при наличии CUDA.

В эксперименте число эпох равно 1, максимальная длина — 128 tokens, train batch size — 16 и eval batch size — 64, learning rate — $2e-05$, weight decay — 0.01. Обучение выполнено на CPU.

5. Experimental Protocol

5.1. Metrics

Основной критерий выбора - F1 токсичного класса: $F1 = 2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$. Дополнительно рассчитываются macro-F1, PR-AUC, ROC-AUC и accuracy. PR-AUC имеет особую ценность при редком положительном классе, а macro-F1 придает одинаковый вес обоим классам.

5.2. Setup and leakage control

Используются `random_state=42`, Python 3.10, scikit-learn 1.7.2, pandas 2.3.3, NumPy 2.2.6, PyArrow 24.0.0, PyTorch 2.8.0 и Transformers 4.56.2. Каждая модель получает одни и те же train/validation/test split. Порог каждой обучаемой модели выбирается только на validation. Победитель также определяется по validation F1. После этого фиксированные модель и порог один раз применяются к test.

Для оценки неопределенности итоговых test-метрик выполнен стратифицированный непараметрический bootstrap фиксированных предсказаний: 1000 повторов, `random_state=42`, границы 2.5% и 97.5% квантилей. Интервалы характеризуют вариативность test-выборки, но не учитывают переобучение модели на разных seed.

5.3. Reproducibility

Зависимости закреплены по версиям. Полный эксперимент запускается одной командой, а все таблицы и рисунки строятся из сохраненных артефактов. Unit-тесты проверяют очистку пересечений и расчет метрик. Отдельный скрипт анализа формирует bootstrap интервалы, сравнение порогов и выборку ошибок из test-предсказаний.

6. Results

Model	Split	Prec.	Recall	F1	Macro F1	PR AUC	ROC AUC
Dummy	val	0.000	0.000	0.000	0.479	0.079	0.500
Dummy	test	0.000	0.000	0.000	0.479	0.079	0.500
TF-IDF + LogReg	val	0.569	0.537	0.553	0.758	0.556	0.875
TF-IDF + LogReg	test	0.550	0.513	0.531	0.746	0.552	0.879
Word+char TF-IDF + SVM	val	0.577	0.549	0.563	0.763	0.591	0.892
Word+char TF-IDF + SVM	test	0.559	0.550	0.554	0.758	0.594	0.895
DistilBERT	val	0.630	0.626	0.628	0.798	0.680	0.932
DistilBERT	test	0.625	0.649	0.637	0.802	0.693	0.938

По validation выбран подход «DistilBERT (fine-tuned)» с порогом 0.622. На независимом test он получил F1=0.637, macro-F1=0.802, PR-AUC=0.693 и ROC-AUC=0.938.

Современный Transformer-baseline сравнивается с классическими моделями на тех же train/validation/test split. DistilBERT получил на test F1=0.637, PR-AUC=0.693 и ROC-AUC=0.938; прирост F1 относительно лучшего классического SVM составляет +0.082.




Рисунок 1. Precision-recall curves на test.




Рисунок 2. Confusion matrix выбранной модели на test.

Итоговая таблица представляет прямое same-protocol сравнение Transformer и классических подходов. Для редкого положительного класса основными метриками являются F1 токсичного класса и PR-AUC: высокая accuracy DummyClassifier, предсказывающего только отрицательный класс, не означает полезного качества.

6.1. Decision threshold

Policy	Threshold	Accuracy	Precision	Recall	F1 toxic
Default	0.500	0.937	0.590	0.674	0.629
Validation-selected	0.622	0.941	0.625	0.649	0.637

Validation-selected threshold 0.622 изменяет recall с 0.674 до 0.649 и F1 с 0.629 до 0.637. Порог не настраивается на test.

Порог выбирался только на validation, а не подгонялся по test. Для сценария предварительного отбора сообщений на ручную проверку рост recall может оправдать снижение precision, если пропуск токсичного комментария дороже увеличения очереди.

6.2. Uncertainty

Metric	Point estimate	95% CI lower	95% CI upper
Precision	0.625	0.612	0.637
Recall	0.649	0.634	0.663
F1 toxic	0.637	0.625	0.649
PR-AUC	0.693	0.679	0.706
ROC-AUC	0.938	0.933	0.941

Интервалы достаточно узкие благодаря размеру test-набора. При этом они не дают оснований утверждать SotA: для такого вывода потребовались бы полностью сопоставимый previous art, несколько seed и статистическое сравнение моделей.

6.3. Error analysis

Матрица ошибок содержит 44,410 true negative, 1,539 false positive, 1,385 false negative и 2,562 true positive. False positive rate равен 3.35%, а false negative rate — 35.09%.

Даже лучшая конфигурация не подходит для полностью автоматической модерации: ошибки требуют ручной проверки, прозрачной политики и возможности апелляции.

Error	Score	Test comment excerpt
FP	0.993	... what a spoiled BRAT MORON we have as a President!!
FP	0.993	how do you know I lived under marxist governments you moron
FN	0.005	I have been an Aeroplan member since it's launch, and have launched a significant number of loyalty programs in Canada (Royal Rewards, CIBC 5% CashBack, various TD Credit Card pro...
FN	0.005	Political motivations, and parties aside. I would love to know peoples actual thoughts on this. Good. Bad? Could we actually get bipartisan support or is it a pipe dream. Addition...

Высоко уверенные false positive часто содержат отдельные оскорбительные слова, которые могут быть цитатой, названием роли или высказыванием о третьем лице. Высоко уверенные false negative нередко выражают токсичность через контекст, иронию или сравнительно редкие формулировки. Некоторые примеры выглядят спорными, что указывает и на возможный шум бинарной разметки. Реальная система должна сохранять возможность ручной проверки и апелляции.

7. Discussion and Limitations

RQ1 подтвержден: TF-IDF + Logistic Regression дает воспроизводимый baseline с test F1=0.531 и существенно превосходит Dummy. По RQ2 итоговая конфигурация word+character TF-IDF + SVM лучше словной логистической регрессии, однако строгий вывод о вкладе character-признаков требует контролируемой абляции при неизменном классификаторе. RQ3 подтвержден напрямую: validation-selected threshold заметно улучшает баланс precision/recall и F1 по сравнению с 0.5. RQ4 проверен прямым дообучением DistilBERT на тех же split; численный результат приведен в общей таблице, а не заимствован из несопоставимого previous art.

Основные ограничения:

- выполнен один детерминированный запуск без оценки вариативности обучения;
- из-за вычислительных ограничений Transformer обучен в сокращенной конфигурации;
- подвыборка не содержит необходимых identity-полей для subgroup/BPSN/BNSP AUC;
- не измерены latency, память и пропускная способность инференса;
- опубликованные результаты previous art получены в другом протоколе;
- порог оптимизируется под F1, а не под явно заданную стоимость ошибок бизнеса.

В безопасном сценарии модель ранжирует сообщения для модератора, а не принимает необратимое решение о блокировке. Для production необходимы мониторинг сдвига данных, аудит подгрупп, журналирование решений и процедура апелляции.

8. Conclusion

Построен воспроизводимый проект бинарной классификации токсичных комментариев с прямым сравнением TF-IDF-моделей и дообученного DistilBERT на фиксированных split. Модель, checkpoint и порог выбираются без доступа к test; bootstrap и анализ ошибок делают итоговые выводы более прозрачными.

Следующий эксперимент должен повторить Transformer-обучение на GPU для нескольких seed, сравнить DistilBERT с RoBERTa, добавить контролируемую абляцию признаков, fairness-метрики и время инференса. До сопоставления с published previous art в идентичном протоколе проект не следует считать state of the art.

Литература

- [1] C. Duchêne, H. Jamet, P. Guillaume, R. Dehak. A benchmark for toxic comment classification on Civil Comments dataset. arXiv:2301.11125, 2023. <https://doi.org/10.48550/arXiv.2301.11125>
- [2] D. Borkan, L. Dixon, J. Sorensen, N. Thain, L. Vasserman. Nuanced Metrics for Measuring Unintended Bias with Real Data for Text Classification. WWW Companion, 2019. <https://doi.org/10.1145/3308560.3317593>
- [3] A. Vaidya, F. Mai, Y. Ning. Empirical Analysis of Multi-Task Learning for Reducing Model Bias in Toxic Comment Detection. arXiv:1909.09758, 2019. <https://doi.org/10.48550/arXiv.1909.09758>
- [4] E. Reichert, H. Qiu, J. Bayrooti. Reading Between the Demographic Lines: Resolving Sources of Bias in Toxicity Classifiers. arXiv:2006.16402, 2020. <https://doi.org/10.48550/arXiv.2006.16402>
- [5] N. Nanda, J. Uesato, S. Gowal. An Empirical Investigation of Learning from Biased Toxicity Labels. ICML Workshop on Socially Responsible Machine Learning, 2021. <https://arxiv.org/abs/2110.01577>
- [6] Jigsaw. Jigsaw Unintended Bias in Toxicity Classification. Kaggle, 2019. <https://www.kaggle.com/competitions/jigsaw-unintended-bias-in-toxicity-classification>
- [7] MTEB. ToxicConversationsClassification dataset card. https://huggingface.co/datasets/mteb/toxic_conversations_50k
- [8] N. Muennighoff et al. MTEB: Massive Text Embedding Benchmark. EACL, 2023. <https://doi.org/10.48550/arXiv.2210.07316>
- [9] V. Sanh, L. Debut, J. Chaumond, T. Wolf. DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. arXiv:1910.01108, 2019. <https://doi.org/10.48550/arXiv.1910.01108>