

Определение токсичности комментариев

Екатерина Бойкова

Final Projects. NLP-course. Spring 2026 replay

2026

Код проекта: https://github.com/Ekotik15/Determining_the_toxicity_of_comments-

Аннотация

В работе исследуется бинарная классификация токсичных англоязычных комментариев Civil Comments. Цель проекта - построить воспроизводимый baseline, корректно учесть дисбаланс классов и оценить итоговую конфигурацию на независимом test-наборе. Сравниваются DummyClassifier, логистическая регрессия на словных TF-IDF-признаках и калиброванный Linear SVM на объединенных словных и символьных TF-IDF-признаках. Модель и порог решения выбираются только по validation F1 токсичного класса. Лучший подход получил на test $F1=0.554$, $PR-AUC=0.594$ и $ROC-AUC=0.895$. Для F1 стратифицированный bootstrap дает 95% интервал $[0.542; 0.566]$. Анализ ошибок показывает, что основные риски связаны с цитированием оскорблений, контекстом, сарказмом, спорными метками и упоминаниями идентичностей. Работа не заявляет state of the art, а формирует проверяемую классическую точку отсчета для будущего сравнения с Transformer-моделями и fairness-aware подходами.

1. Introduction

Автоматическая модерация необходима для площадок, на которых ручная проверка каждого сообщения невозможна. Задача токсичности сложна из-за дисбаланса, субъективности разметки, зависимости от контекста и того, что одинаковая лексика может встречаться как в прямом оскорблении, так и в цитате или критическом обсуждении. False negative пропускает потенциально вредный контент, а false positive может необоснованно ограничить допустимое высказывание.

Формально для комментария x требуется оценить вероятность токсичности $p(y=1|x)$ и получить метку $\hat{y} \in \{0,1\}$. Положительный класс составляет около 8%, поэтому ассигасу не используется как основной критерий.

Работа отвечает на три исследовательских вопроса:

- RQ1. Насколько сильным baseline является линейная модель на TF-IDF при существенном дисбалансе классов?
- RQ2. Улучшает ли объединение словных и символьных признаков итоговую конфигурацию относительно словного baseline?
- RQ3. Как выбор порога влияет на precision, recall и F1 токсичного класса?

Основные результаты и вклад проекта:

- реализован протокол train/validation/test без использования test для выбора модели, гиперпараметров или порога;
- все модели оцениваются единым набором метрик;
- классический подход доведен до воспроизводимого CLI-эксперимента с сохранением метрик, графиков, модели и предсказаний;
- добавлены bootstrap-интервалы, сравнение порогов и анализ реальных ошибок;

- Streamlit-приложение использует именно выбранную модель и зафиксированный порог.

1.1. Team

Екатерина Бойкова выполнила постановку задачи, подготовку данных, разработку и сравнение моделей, анализ результатов, оформление отчета и демонстрационного приложения.

2. Related Work

Линейные модели на TF-IDF остаются полезными baseline для классификации текста: они быстры, сравнительно интерпретируемы и не требуют GPU. Символьные n-граммы особенно уместны для пользовательского контента, поскольку устойчивы к опечаткам, обфускации и вариантам написания токсичной лексики.

Duchêne et al. [1] сравнили CNN, RNN, BERT, DistilBERT, RoBERTa, XLNet и CCT на Civil Comments. В их многометочной постановке Transformer-модели достигли AUROC около 0.98, а RoBERTa с focal loss показала лучший AUROC среди рассмотренных конфигураций. DistilBERT обеспечил близкое качество при меньшем времени инференса. Выбранные численные результаты этой работы приведены ниже.

Model	Protocol	AUROC	Macro F1	Recall
DistilBERT	multilabel, 310k train	0.9804	0.3879	0.9001
RoBERTa BCE	multilabel, 310k train	0.9813	0.4749	0.8891
RoBERTa focal loss	multilabel, 310k train	0.9818	0.4648	0.8839
BiLSTM	multilabel, 310k train	0.9754	0.3638	0.8761

Прямое ранжирование этих значений и результатов настоящего проекта некорректно: в [1] использованы многометочная постановка, около 310 тысяч обучающих примеров, другие признаки целевой переменной и иной протокол оценки. Таблица показывает уровень previous art и мотивирует следующий этап исследования, но не является основанием для заявления SotA.

Borkan et al. [2] предложили subgroup AUC, BPSN AUC и BNSP AUC для измерения unintended bias. Эти метрики обнаруживают случаи, когда общая ROC-AUC скрывает систематические ошибки на комментариях с упоминаниями идентичностей. Vaidya et al. [3] исследовали multi-task learning с совместным предсказанием токсичности и идентичностей. Reichert et al. [4] сравнили балансировку, TF-IDF, GloVe, нейронные сети и LSTM. Nanda et al. [5] показали, что лидер по общей AUC не обязательно является лучшим по fairness-метрикам.

Настоящая работа занимает промежуточную позицию между тривиальным baseline и ресурсоемкими Transformer-моделями. Ее задача - получить честную, компактную и воспроизводимую точку отсчета на фиксированном бинарном протоколе.

3. Task and Dataset

Используется mteb/toxic_conversations_50k [7], подготовленный на основе Jigsaw Unintended Bias in Toxicity Classification [6] и Civil Comments. Данные содержат англоязычные комментарии новостных площадок. Лицензия опубликованной версии - CC BY 4.0. В используемом Parquet-представлении доступны 50 000 train- и 50 000 test-строк с бинарными полями text и label.

Положительная метка соответствует токсичному комментарию. Перед обучением удаляются пустые строки и дубликаты по тексту. Из train дополнительно исключаются строки, дословно встречающиеся в test. После очистки train делится стратифицированно в пропорции 80/20; исходный test сохраняется независимым.

Split	Rows	Toxic	Toxic share	Median chars
train	39,832	3,166	7.95%	204
validation	9,958	791	7.94%	209
test	49,896	3,947	7.91%	202

Баланс классов практически одинаков во всех split: 7.91-7.95% токсичных комментариев. Это снижает риск случайного изменения prior между split, но не устраняет проблему редкого положительного класса.

3.1. Data provenance and risks

Код загружает публичное Parquet-представление набора и кэширует его локально. Для полного воспроизведения следует сохранять дату доступа, URL и контрольные суммы кэшированных файлов, поскольку автоматически конвертируемый источник может обновляться. Карточка набора указывает на дополнительную обработку в МТЕВ/ММТЕВ, поэтому в библиографии приведены как исходная Jigsaw-задача, так и МТЕВ [6-8].

Разметка токсичности субъективна и может содержать неоднозначные случаи. Данные также отражают язык и общественный контекст периода сбора. Модель не должна использоваться как единственный механизм блокировки пользователя.

4. Proposed Approach

4.1. Text representation

Словный векторизатор использует униграммы и биграммы, min_df=2, max_df=0.995, sublinear TF и до 40 000 признаков. Символьный векторизатор использует char_wb n-граммы длины 3-5, min_df=3, sublinear TF и до 40 000 признаков.

Для документа d и термина t используется вес $TF\text{-}IDF(t,d) = TF(t,d) \times \log(N / DF(t))$, где N - число документов, а $DF(t)$ - число документов, содержащих терм. При sublinear TF исходная частота заменяется на $1 + \log(TF)$.

4.2. Classifier and calibration

Объединенный разреженный вектор подается в LinearSVC с $C=1.5$ и `class_weight="balanced"`. Decision scores калибруются sigmoid-методом на трех фолдах с помощью CalibratedClassifierCV. Порог выбирается на validation по максимуму F1 положительного класса.

SMOTE не используется: интерполяция разреженных TF-IDF-векторов создает точки, которые не соответствуют реальным текстам. Дисбаланс учитывается весами классов, целевой метрикой и выбором порога.

4.3. Competitive approaches

Сравниваются три конфигурации:

- Dummy prior - нижняя граница, использующая только частоту классов;
- word TF-IDF + Logistic Regression с $C=4.0$, `class_weight="balanced"` и `solver="liblinear"`;
- word+character TF-IDF + calibrated Linear SVM - основной кандидат.

Сравнение показывает преимущество итоговой конфигурации, но не является строгой абляцией символьных признаков: одновременно меняются представление, классификатор и калибровка. Поэтому улучшение нельзя приписывать только character n-граммам.

5. Experimental Protocol

5.1. Metrics

Основной критерий выбора - F1 токсичного класса: $F1 = 2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$. Дополнительно рассчитываются macro-F1, PR-AUC, ROC-AUC и accuracy. PR-AUC имеет особую ценность при редком положительном классе, а macro-F1 придает одинаковый вес обоим классам.

5.2. Setup and leakage control

Используются random_state=42, Python 3.10, scikit-learn 1.7.2, pandas 2.3.3, NumPy 2.2.6 и PyArrow 24.0.0. Каждая модель получает один и тот же train. Порог каждой обучаемой модели выбирается только на validation. Победитель также определяется по validation F1. После этого фиксированные модель и порог один раз применяются к test.

Для оценки неопределенности итоговых test-метрик выполнен стратифицированный непараметрический bootstrap фиксированных предсказаний: 1000 повторов, random_state=42, границы 2.5% и 97.5% квантилей. Интервалы характеризуют вариативность test-выборки, но не учитывают переобучение модели на разных seed.

5.3. Reproducibility

Зависимости закреплены по версиям. Полный эксперимент запускается одной командой, а все таблицы и рисунки строятся из сохраненных артефактов. Unit-тесты проверяют очистку пересечений и расчет метрик. Отдельный скрипт анализа формирует bootstrap интервалы, сравнение порогов и выборку ошибок из test-предсказаний.

6. Results

Model	Split	Prec.	Recall	F1	Macro F1	PR AUC	ROC AUC
Dummy	val	0.000	0.000	0.000	0.479	0.079	0.500
Dummy	test	0.000	0.000	0.000	0.479	0.079	0.500
TF-IDF + LogReg	val	0.569	0.537	0.553	0.758	0.556	0.875
TF-IDF + LogReg	test	0.550	0.513	0.531	0.746	0.552	0.879
Word+char TF-IDF + SVM	val	0.577	0.549	0.563	0.763	0.591	0.892
Word+char TF-IDF + SVM	test	0.559	0.550	0.554	0.758	0.594	0.895

По validation выбран подход «Word+char TF-IDF + Linear SVM» с порогом 0.232. На независимом test он получил F1=0.554, macro-F1=0.758, PR-AUC=0.594 и ROC-AUC=0.895.




Рисунок 1. Precision-recall curves на test.




Рисунок 2. Confusion matrix выбранной модели на test.

Dummy prior получает более 92% ассурасу, но не находит ни одного токсичного комментария. Это демонстрирует непригодность ассурасу как основной метрики. Итоговый SVM превосходит логистическую регрессию на test по F1 токсичного класса (0.554 против 0.531), макро-F1 (0.758 против 0.746), PR-AUC (0.594 против 0.552) и ROC-AUC (0.895 против 0.879).

6.1. Decision threshold

Policy	Threshold	Accuracy	Precision	Recall	F1 toxic
Default	0.500	0.939	0.795	0.315	0.451
Validation-selected	0.232	0.930	0.559	0.550	0.554

Снижение порога с 0.500 до 0.232 повышает recall с 0.315 до 0.550 и F1 с 0.451 до 0.554. Цена улучшения - снижение precision с 0.795 до 0.559 и небольшое снижение ассурасу. Для сценария предварительного отбора сообщений на ручную проверку такой обмен оправдан: пропуск токсичного комментария дороже увеличения очереди проверки.

6.2. Uncertainty

Metric	Point estimate	95% CI lower	95% CI upper
Precision	0.559	0.546	0.572
Recall	0.550	0.534	0.564
F1 toxic	0.554	0.542	0.566
PR-AUC	0.594	0.579	0.608
ROC-AUC	0.895	0.889	0.900

Интервалы достаточно узкие благодаря размеру test-набора. При этом они не дают оснований утверждать SotA: для такого вывода потребовались бы полностью сопоставимый previous art, несколько seed и статистическое сравнение моделей.

6.3. Error analysis

Матрица ошибок содержит 44 236 true negative, 1 713 false positive, 1 777 false negative и 2 170 true positive. False positive rate равен 3.73%, а false negative rate - 45.02%. Последнее значение показывает, что даже после настройки порога модель не подходит для полностью автоматической модерации.

Error	Score	Test comment excerpt
FP	0.995	... what a spoiled BRAT MORON we have as a President!!
FP	0.993	Moron extrodinare
FN	0.002	I was getting everything right but quit when I reached the second "Drake" question. Is this quiz for readers to have fun with or another goddammed advertorial?
FN	0.003	Pardon me? Trump said "it's a military operation." He did not say "it's like a military operation." Amazing the baloney Trump supporters try to promote.

Высоко уверенные false positive часто содержат отдельные оскорбительные слова, которые могут быть цитатой, названием роли или высказыванием о третьем лице. Высоко уверенные false negative нередко выражают токсичность через контекст, иронию или сравнительно редкие формулировки. Некоторые примеры выглядят спорными, что указывает и на возможный шум бинарной разметки. Реальная система должна сохранять возможность ручной проверки и апелляции.

7. Discussion and Limitations

RQ1 подтвержден: TF-IDF + Logistic Regression дает воспроизводимый baseline с test F1=0.531 и существенно превосходит Dummy. По RQ2 итоговая конфигурация word+character TF-IDF + SVM лучше словной логистической регрессии, однако строгий вывод о вкладе character-признаков требует контролируемой абляции при неизменном классификаторе. RQ3 подтвержден напрямую: validation-selected threshold заметно улучшает баланс precision/recall и F1 по сравнению с 0.5.

Основные ограничения:

- выполнен один детерминированный запуск без оценки вариативности обучения;
- отсутствует Transformer-baseline на тех же split;
- подвыборка не содержит необходимых identity-полей для subgroup/BPSN/BNSP AUC;
- не измерены latency, память и пропускная способность инференса;
- опубликованные результаты previous art получены в другом протоколе;
- порог оптимизируется под F1, а не под явно заданную стоимость ошибок бизнеса.

В безопасном сценарии модель ранжирует сообщения для модератора, а не принимает необратимое решение о блокировке. Для production необходимы мониторинг сдвига данных, аудит подгрупп, журналирование решений и процедура апелляции.

8. Conclusion

Построен воспроизводимый проект бинарной классификации токсичных комментариев. Лучшей из проверенных классических конфигураций стала word+character TF-IDF + calibrated Linear SVM. На независимом test она получила $F1=0.554$, $PR-AUC=0.594$ и $ROC-AUC=0.895$. Выбор порога на validation повысил F1 относительно стандартного порога 0.5, а bootstrap и анализ ошибок сделали выводы более прозрачными.

Следующий эксперимент должен обучить DistilBERT/RoBERTa на тех же фиксированных split, добавить контролируемую абляцию признаков, несколько seed, fairness-метрики и измерение времени инференса. До такого сравнения проект следует рассматривать как сильный инженерно оформленный baseline, а не как state of the art.

Литература

- [1] C. Duchêne, H. Jamet, P. Guillaume, R. Dehak. A benchmark for toxic comment classification on Civil Comments dataset. arXiv:2301.11125, 2023. <https://doi.org/10.48550/arXiv.2301.11125>
- [2] D. Borkan, L. Dixon, J. Sorensen, N. Thain, L. Vasserman. Nuanced Metrics for Measuring Unintended Bias with Real Data for Text Classification. WWW Companion, 2019. <https://doi.org/10.1145/3308560.3317593>
- [3] A. Vaidya, F. Mai, Y. Ning. Empirical Analysis of Multi-Task Learning for Reducing Model Bias in Toxic Comment Detection. arXiv:1909.09758, 2019. <https://doi.org/10.48550/arXiv.1909.09758>
- [4] E. Reichert, H. Qiu, J. Bayrooti. Reading Between the Demographic Lines: Resolving Sources of Bias in Toxicity Classifiers. arXiv:2006.16402, 2020. <https://doi.org/10.48550/arXiv.2006.16402>
- [5] N. Nanda, J. Uesato, S. Gowal. An Empirical Investigation of Learning from Biased Toxicity Labels. ICML Workshop on Socially Responsible Machine Learning, 2021. <https://arxiv.org/abs/2110.01577>
- [6] Jigsaw. Jigsaw Unintended Bias in Toxicity Classification. Kaggle, 2019. <https://www.kaggle.com/competitions/jigsaw-unintended-bias-in-toxicity-classification>
- [7] MTEB. ToxicConversationsClassification dataset card. https://huggingface.co/datasets/mteb/toxic_conversations_50k
- [8] N. Muennighoff et al. MTEB: Massive Text Embedding Benchmark. EACL, 2023. <https://doi.org/10.48550/arXiv.2210.07316>